


# 1 млрд токенов в сутки на потребительских видеокартах

ЧЕРНОВИК

Александр Сапронов

[t.me/axsapronov](https://t.me/axsapronov)

Data Fest Siberia 7 • Новосибирск • 10 октября 2026



# План доклада

01 Зачем собирать свою ИИ-инфраструктуру?

---

02 Подготовка — что ожидают пользователи, как запускать

---

03 Начинаем — запуск первой модели, ollama

---

04 Продолжаем — Proxmox, GPUStack, llama.cpp

---

05 Стабилизация — агенты, балансер, vllm




**Александр Сапронов**

IT MANAGER (CTO)

Решаю бизнес задачи в IT.  
MTC, Avito, Welltory


[t.me/axsapronov](https://t.me/axsapronov) · [a@sapronov.me](mailto:a@sapronov.me)

# ИИ в 2026 — удобная и дорогая технология




Компании хотят возврата инвестиций, так что открывайте кошелек шире

# IT в 2026 — полоса юридических препятствий



Для данных существуют границы и незаконное пересечение имеет последствия

# Гибридная инфраструктура — способ решения



РИСКИ, КОТОРЫЕ ЗАКРЫВАЕТ ГИБРИД



## Юридические

данные не уходят третьим сторонам



## Финансовые

предсказуемая стоимость



## Vendor lock

независимость от провайдера

Cloud — чтобы быстро двигаться, self-hosted — чтобы долго двигаться

**С чего начать Self-hosted?**

# Что ожидают пользователи

● СКОРОСТЬ

**80—100** ток/с

50 — разработка с агентами · 25 — чат

● КОНТЕКСТ

**256k** токенов

200k — оптимум для Cursor · 100k — документация

● ОБЪЁМ

**50M** токенов/сутки на чел.

3—4 задачи в день

● КАЧЕСТВО

**≥ Claude 3.5 Sonnet**

Архитектурное ревью · реализация фич целиком

● API

**OpenAI / Anthropic**

Совместимый API — стандартные клиенты, SDK и агенты

● УПРАВЛЕНИЕ

**Статистика и управление доступами**

Токены и запросы по пользователям и моделям, API-ключи

# Какую модель взять?

## • ≤ 3B

Документы, аудио, спец. задачи

### Mellum-4b

Автодополнение кода

### MinerU / PaddleOCR-VL

PDF → Markdown · 1B

### DeepSeek-OCR

Batch OCR · 3B MoE · MIT

### Whisper-Podlodka

ASR · русский

## • ≤ 8B

RAG · поиск

### bge-m3

dense + sparse + ColBERT

### Qwen3-Embedding

код · 32K · MRL

### Qwen3-Reranker-4B

cross-encoder · 32K

### ruBERT-ruLaw

юридический RAG

## • ≤ 15B

Рефакторинг · Базовый SDLC

### Mellum2-12B-A2.5B

Оркестрация задач · выполнение команд

### Devstral-Small-2-24B

Mistral · agentic · 24B

### DeepSeek Coder V2 Lite

MoE · 2.4B active · MIT

## • ≤ 35B

Проектирование и реализация

### Qwen3.8-27B

НАШ ВЫБОР


MTP · 262K контекст · vision

### T-pro-it-2.1

RU RAG · tools > Qwen3-32B

# Чем запустить LLM модель?


| ДВИЖОК       | СЛОЖНОСТЬ                                                          | ВОЗМОЖНОСТИ                                                        | КОГДА БРАТЬ                           |
|--------------|--------------------------------------------------------------------|--------------------------------------------------------------------|---------------------------------------|
| Ollama       | <div><div></div><div></div><div></div><div></div><div></div></div> | <div><div></div><div></div><div></div><div></div><div></div></div> | «Хочу просто попробовать ИИ»          |
| llama.cpp    | <div><div></div><div></div><div></div><div></div><div></div></div> | <div><div></div><div></div><div></div><div></div><div></div></div> | «Хочу запустить, но ресурсов немного» |
| vLLM         | <div><div></div><div></div><div></div><div></div><div></div></div> | <div><div></div><div></div><div></div><div></div><div></div></div> | «Хочу production ИИ, ресурсы есть»    |
| SGLang       | <div><div></div><div></div><div></div><div></div><div></div></div> | <div><div></div><div></div><div></div><div></div><div></div></div> | «Хочу ИИ, готов страдать»             |
| TensorRT-LLM | <div><div></div><div></div><div></div><div></div><div></div></div> | <div><div></div><div></div><div></div><div></div><div></div></div> | «Я богат, очень богат. Заверните всё» |



Движок — это способ раскладки модели в VRAM + API обращения к модели

**Поехали запускать!**

# Запуск первой модели, ollama



ollama — отличный способ "начать", прямо сейчас

# Не получилось — шумит, тормозит, тупит

| Параметр     | Ожидание                          | Реальность                      | Статус |
|--------------|-----------------------------------|---------------------------------|--------|
| ● СКОРОСТЬ   | 80–100 ток/сек                    | 10–20 ток/сек                   | ✗      |
| ● КОНТЕКСТ   | 256k токенов                      | 4k–32k (дефолт Ollama)          | ✗      |
| ● ОБЪЁМ      | 50M токенов/сутки на чел.         | 1 пользователь, всё очень долго | ✗      |
| ● КАЧЕСТВО   | ≥ Claude 3.5 Sonnet               | Непонятно                       | ✗      |
| ● API        | OpenAI / Anthropic                | Ollama API (OpenAI-совместимый) | ~      |
| ● УПРАВЛЕНИЕ | Статистика и управление доступами | Урезанная статистика и доступы  | ✗      |

## ОСОБЕННОСТИ

### Шум · Telsa M40

250W

вентилятор на 100% под нагрузкой,  
NVIDIA уже не поддерживает

### Холодный старт

keep\_alive 5m

модель выгружается из VRAM спустя 5  
минут, по-умолчанию

### Не production

тяжело организовать доступ по ключам,  
без доступа через VPN

# Что дальше? Больше видеокарт и llama.cpp

01

## Отказаться от Tesla M40

запустить серверы с RTX 3060/4070 Ti

● ШУМ

02

## Заменить ollama на llama.cpp

больше инструкций, больше опыта, меньше посредников

● ОБЪЁМ ● СКОРОСТЬ

03

## Объединить серверы в Proxmox кластер

централизованный контроль за RAM, VRAM, SSD

● НАДЁЖНОСТЬ

04

## Настроить оркестратор


статистика, управление пользователям, API-ключам

● УПРАВЛЕНИЕ

# GPUStack — оркестратор ИИ

# Модели

## Hugging Face → replicas N → auto-restart



The screenshot displays the Hugging Face Model Replicas page. At the top, there's a header with the Hugging Face logo and the text "Models". Below this, a large heading reads "Hugging Face → replicas N → auto-restart". The main content area is a grid of model cards. Each card shows the model name, its version, the operating system (OS), the container image, and the number of replicas. A red arrow points to the "Owen3.5-0.8B" model card, which is highlighted with a red circle and a red arrow pointing to it from the right. The models listed include ERNIE-Inner, GLM-4, Gemma-4, Mistral, and others. The "Owen3.5-0.8B" model is currently at version 0.8B and has 0 replicas.

| Model                     | Version | OS        | Image                            | Replicas |
|---------------------------|---------|-----------|----------------------------------|----------|
| ERNIE-Inner               | 0.0.0.0 | OS: 04-02 | Image: apache:2.0                | 0        |
| Gemma-4-E4B-it            | 0.0.0.0 | OS: 04-02 | Image: apache:2.0                | 4B       |
| Voxtral-4-TTS-2603        | 0.0.0.0 | OS: 03-31 | Image: co-ty-cp:4.0              | 0        |
| NVIDIA-Memotron-3-Nano-4B | 0.0.0.0 | OS: 03-02 | Image: mvidia-open-model-licanse | 4B       |
| Owen3.5-0.8B              | 0.8B    | OS: 03-02 | Image: apache:2.0                | 0        |

The image shows the OpenAI Playground interface. At the top, there's a navigation bar with 'API', 'Docs', 'Pricing', 'About', and 'Contact'. Below this, the 'OpenAI Playground' title is visible. The main area is divided into a chat window and a settings panel. The chat window shows a user message: 'Write a Rust program to read a file.' and an assistant response: 'Here's a simple Rust program to read a file...'. The code provided is: 

```
use std::fs;

fn main() {
    let filename = "example.txt";
}
```

 The settings panel on the right includes sliders for Temperature (set to 1), Max Tokens (set to 1024), Top P (set to 1), Frequency Penalty (set to 0), and Presence Penalty (set to 0). There are also input fields for Seed and Stop Sequence. At the bottom of the chat window, it shows 'Token Usage: 1082' and 'Output: 73.1 Tokens'.

The screenshot shows the 'Движки' (Engines) section of the Dvzhihi website. It features a grid of inference runtimes, each with a logo, name, and a list of supported frameworks. The runtimes listed are vLLM, SGLang, Llama.cpp, PaddleX-GenAI-Server, and others. The supported frameworks include cuda, openvino, and others. The website is in Russian, with the main heading 'подключаемые inference-рантаймы' (connectable inference runtimes).

**Статистика**

токены и запросы по пользователям и ключам

Summary Cards:

- Input Tokens: 16.2B
- Output Tokens: 92.1M
- Total Tokens: 16.3B
- API Requests: 343K
- Models Used: 92


Chart: Total Tokens (Group by Day)

| Day   | Total Tokens |
|-------|--------------|
| 09-01 | ~1000000000  |
| 09-02 | ~600000000   |
| 09-03 | ~1000000000  |
| 09-04 | ~800000000   |
| 09-05 | ~600000000   |
| 09-06 | ~500000000   |
| 09-07 | ~600000000   |
| 09-08 | ~600000000   |
| 09-09 | ~500000000   |
| 09-10 | ~500000000   |
| 09-11 | ~300000000   |
| 09-12 | ~400000000   |
| 09-13 | ~200000000   |
| 09-14 | ~300000000   |
| 09-15 | ~400000000   |
| 09-16 | ~300000000   |
| 09-17 | ~200000000   |
| 09-18 | ~200000000   |
| 09-19 | ~500000000   |
| 09-20 | ~600000000   |
| 09-21 | ~400000000   |
| 09-22 | ~300000000   |
| 09-23 | ~800000000   |
| 09-24 | ~400000000   |
| 09-25 | ~400000000   |
| 09-26 | ~1200000000  |
| 09-27 | ~200000000   |
| 09-28 | ~800000000   |
| 09-29 | ~600000000   |
| 09-30 | ~400000000   |

| Name                 | Input Tokens | Input Tokens Cached | Output Tokens | Total Tokens | API Requests | Last Active |
|----------------------|--------------|---------------------|---------------|--------------|--------------|-------------|
| open                 | 11961078553  | 10347601835         | 61363471      | 12042442034  | 145007       | 2020-09-30  |
| bge-m3-russian-legal | 2487152006   | 0                   | 0             | 2487152006   | 67918        | 2020-09-30  |

**Продолжаем тюнить**

# Proxmox, GPUStack, llama.cpp



# Почти получилось — для 1 отдела хватит

| Параметр     | Ожидание                          | Реальность                   | Статус |
|--------------|-----------------------------------|------------------------------|--------|
| ● СКОРОСТЬ   | 80–100 ток/сек                    | 50–70 ток/сек                | ~      |
| ● КОНТЕКСТ   | 256k токенов                      | 32–64k                       | ✗      |
| ● ОБЪЁМ      | 50M токенов/сутки на чел.         | 2–3 пользователя, но тормоза | ✗      |
| ● КАЧЕСТВО   | ≥ Claude 3.5 Sonnet               | Не ясно как подобрать модель | ~      |
| ● API        | OpenAI / Anthropic                | OpenAI-совместимый           | ✓      |
| ● УПРАВЛЕНИЕ | Статистика и управление доступами | GPUStack                     | ✓      |

## ОСОБЕННОСТИ

### Модели еле влезают

RAM помогает запихать модель

### 2–3 пользователя — предел

не хватает пропускной способности

### GPUStack — унификация

ключи, статистика, модели через UI

llama.cpp умеет запускать модели в RAM, когда не хватает VRAM

# Что дальше? RTX 3090 + vLLM

01

## Перейти на пары RTX 3090

Это даст 48 GB VRAM

02

## Заменить llama.cpp на vLLM

Движок адаптирован под production нагрузку

03

## Подобрать версию модели под железо

Изучить виды квантизации, особенности алгоритмов

04

## Настроить контроль температура-мощность

Написать демона, который сам будет следить за перегревом

05

## Запустить балансировщик LLM трафика

sticky session + prefix-aware (vllm router или свой балансер)

06

## Встроить ИИ в рабочий процесс

CI review, SDLC, RAG

# Подбор модели под железо

$$\text{VRAM} = \text{BECA (КВАНТИЗАЦИЯ)} + \text{KV-CACHE (КОНТЕКСТ} \times \text{CONCURRENCY)} + \text{OVERHEAD (~10-15\%)}$$


≈ 24 GB

48 GB

## FP16

без квантизации

x OOM



### 01 Возможный вес модели

Размер файлов модели –  
минимальный бъем VRAM

14 GB → 14+ GB VRAM

>

### 02 Требуемый объем памяти

в зависимости от движка

llama.cpp → 1 x размер модели

vLLM → 2 x размер модели

>

### 03 Квантизация

по поколению GPU


Ampere (30\*\*) → AWQ (W4A16)

Ada Lovelace (40\*\*) → NVFP4

На Ampere нет FP8 — поэтому 27B на 2x3090 живёт в AWQ INT4

# Что настраивать в движке inference?


| Группа                   | vLLM                                                               | llama.cpp / Ollama                 |
|--------------------------|--------------------------------------------------------------------|------------------------------------|
| ● A Память / KV-cache    | gpu-memory-utilization 0.85-0.92 · max-model-len                   | n_ctx · n_gpu_layers               |
| ● B Batching / scheduler | max-num-seqs · max-num-batched-tokens 4096-16384 · chunked-prefill | n_batch · threads = физ. ядра      |
| ● C Ускорения            | speculative decoding (MTP/EAGLE) · flash attn · prefix caching     | flash attention · MTP draft-tokens |
| ● D Железо / топология   | tensor-parallel-size · pipeline-parallel-size · OMP_NUM_THREADS    | n_gpu_layers (offload) · --threads |



конфиг для qwen3.8-27b


Один параметр за раз — иначе не поймёшь, что именно дало эффект

# Особенности LLM трафика



Запрос обрабатывается секунды, кэш протухает — балансировать надо нагрузку и кэш


# Балансировка LLM трафика



Балансер роутит по кэшу и нагрузке: сессия — на тёплую, новую — на холодную

**Что в итоге?**

# AWQ, vLLM, балансер



# Итоги

| Параметр     | Ожидание                          | Реальность                                       | Статус |
|--------------|-----------------------------------|--------------------------------------------------|--------|
| ● СКОРОСТЬ   | 80–100 ток/сек                    | 80-100 ток/сек на пользователя                   | ✓      |
| ● КОНТЕКСТ   | 256k токенов                      | 256K (262144)                                    | ✓      |
| ● ОБЪЁМ      | 50M токенов/сутки на чел.         | 1 млрд токенов/сутки (пик), 600-750M в среднем   | ✓      |
| ● КАЧЕСТВО   | ≥ Claude 3.5 Sonnet               | Qwen3.8: Terminal-Bench 73, DeepSWE 42.2         | ✓      |
| ● API        | OpenAI / Anthropic                | GPUStack — OpenAI-совместимый                    | ✓      |
| ● УПРАВЛЕНИЕ | Статистика и управление доступами | GPUStack: счётчики по пользователям и API-ключам | ✓      |

## ОСОБЕННОСТИ

**10 сотрудников работают**

Каждый может в 3 потока кодить

**<74°C температура видеокарт**

При допустимой в 93°C

**ИИ встроен везде**

Агенты, Chat, RAG, DeerFlow, Dify...

Итого: 12 видеокарт (8×3090, 2×4070, 2×3060) и 1 TB RAM

# Спасибо!

## Вопросы?

1 млрд токенов в сутки — это не про железо.  
Это про то, что я перестал быть пользователем  
API и стал оператором инфраструктуры

Александр Сапронов

[a@sapronov.me](mailto:a@sapronov.me) · [t.me/axsapronov](https://t.me/axsapronov)



Ссылка на слайды