


1 млрд токенов в сутки на потребительских видеокартах

Александр Сапронов

t.me/axsapronov

Data Fest Siberia 7 · Новосибирск · 10 октября 2026



План доклада

- 01 Зачем собирать свою ИИ-инфраструктуру?
- 02 Подготовка — что ожидают пользователи, как запускать
- 03 Начинаем — запуск первой модели, ollama
- 04 Продолжаем — Proxmox, GPUStack, llama.cpp
- 05 Стабилизация — агенты, балансер, vllm




Александр Сапронов

IT MANAGER (CTO)

Решаю бизнес задачи в IT.
MTC, Avito, Welltory


t.me/axsapronov · a@sapronov.me

ИИ в 2026 — удобная и дорогая технология




Компании хотят возврата инвестиций, так что открывайте кошелек шире

IT в 2026 — полоса юридических препятствий



Для данных существуют границы и незаконное пересечение имеет последствия

Гибридная инфраструктура — способ решения



РИСКИ, КОТОРЫЕ ЗАКРЫВАЕТ ГИБРИД



Юридические

данные не уходят третьим сторонам



Финансовые

предсказуемая стоимость



Vendor lock

независимость от провайдера

Cloud — чтобы быстро двигаться, self-hosted — чтобы долго двигаться

С чего начать Self-hosted?

Что ожидают пользователи

● СКОРОСТЬ

80—100 ток/с

50 — разработка с агентами · 25 — чат

● КОНТЕКСТ

256k токенов

200k — оптимум для Cursor · 100k — документация

● ОБЪЁМ

50M токенов/сутки на чел.

3—4 задачи в день

● КАЧЕСТВО

≥ Claude 3.5 Sonnet

Архитектурное ревью · реализация фич целиком

● API

OpenAI / Anthropic

Совместимый API — стандартные клиенты, SDK и агенты

● УПРАВЛЕНИЕ

Статистика и управление доступами

Токены и запросы по пользователям и моделям, API-ключи

Какую модель взять?

• ≤ 3B

Документы, аудио, спец. задачи

Mellum-4b

Автодополнение кода

MinerU / PaddleOCR-VL

PDF → Markdown · 1B

DeepSeek-OCR

Batch OCR · 3B MoE · MIT

Whisper-Podlodka

ASR · русский

• ≤ 8B

RAG · поиск

bge-m3

dense + sparse + ColBERT

Qwen3-Embedding

код · 32K · MRL

Qwen3-Reranker-4B

cross-encoder · 32K

ruBERT-ruLaw

юридический RAG

• ≤ 15B

Рефакторинг · Базовый SDLC

Mellum2-12B-A2.5B

Оркестрация задач · выполнение команд

Devstral-Small-2-24B

Mistral · agentic · 24B

DeepSeek Coder V2 Lite

MoE · 2.4B active · MIT

• ≤ 35B

Проектирование и реализация

Qwen3.8-27B

НАШ ВЫБОР


MTP · 262K контекст · vision

T-pro-it-2.1

RU RAG · tools > Qwen3-32B

Чем запустить LLM модель?


ДВИЖОК	СЛОЖНОСТЬ	ВОЗМОЖНОСТИ	КОГДА БРАТЬ
Ollama	● ○ ○ ○ ○	● ○ ○ ○ ○	«Хочу просто попробовать ИИ»
llama.cpp	● ● ○ ○ ○	● ● ● ○ ○	«Хочу запустить, но ресурсов немного»
vLLM	● ● ● ○ ○	● ● ● ● ○	«Хочу production ИИ, ресурсы есть»
SGLang	● ● ● ● ○	● ● ● ● ○	«Хочу ИИ, готов страдать»
TensorRT-LLM	● ● ● ● ●	● ● ● ● ●	«Я богат, очень богат. Заверните всё»



Движок — это способ раскладки модели в VRAM + API обращения к модели

Поехали запускать!

Запуск первой модели, ollama



ollama — отличный способ "начать", прямо сейчас

Не получилось — шумит, тормозит, тупит

Параметр	Ожидание	Реальность	Статус
● СКОРОСТЬ	80–100 ток/сек	10–20 ток/сек	✗
● КОНТЕКСТ	256k токенов	4k–32k (дефолт Ollama)	✗
● ОБЪЁМ	50M токенов/сутки на чел.	1 пользователь, всё очень долго	✗
● КАЧЕСТВО	≥ Claude 3.5 Sonnet	Непонятно	✗
● API	OpenAI / Anthropic	Ollama API (OpenAI-совместимый)	~
● УПРАВЛЕНИЕ	Статистика и управление доступами	Урезанная статистика и доступы	✗

ОСОБЕННОСТИ

Шум · Telsa M40

250W

вентилятор на 100% под нагрузкой,
NVIDIA уже не поддерживает

Холодный старт

keep_alive 5m

модель выгружается из VRAM спустя 5
минут, по-умолчанию

Не production

тяжело организовать доступ по ключам,
без доступа через VPN

Что дальше? Больше видеокарт и llama.cpp

01

Отказаться от Tesla M40

запустить серверы с RTX 3060/4070 Ti

● ШУМ

02

Заменить ollama на llama.cpp

больше инструкций, больше опыта, меньше посредников

● ОБЪЁМ ● СКОРОСТЬ

03

Объединить серверы в Proxmox кластер

централизованный контроль за RAM, VRAM, SSD

● НАДЁЖНОСТЬ

04

Настроить оркестратор

статистика, управление пользователям, API-ключам

● УПРАВЛЕНИЕ

GPUStack — оркестратор ИИ

Модели

Hugging Face → replicas N → auto-restart

ERNIE-Image 05-04-07 @ apache-2.0 [PVP] [8]	GLM-5.1 05-04-04 @ mit [LLM] [188k context] [reasoning] [tools] [7.5B]	Gemma-4-22B-R 05-04-02 @ apache-2.0 [LLM] [128k context] [vision] [2B]
Gemma-4-E4B-R 05-04-02 @ apache-2.0 [LLM] [128k context] [vision] [4B]	Gemma-4-28B-A4B-R 05-04-02 @ apache-2.0 [LLM] [256k context] [vision] [28B-A4B]	Gemma-4-31B-R 05-04-02 @ apache-2.0 [LLM] [256k context] [vision] [31B]
Voxtral-4B-TTS-2003 05-03-31 @ co-lyric-4.0 [text-to-speech] [4B]	Nemotron-Cascade-2-30B-A3B 05-03-19 @ nvidia-open-model-license [LLM] [1M context] [reasoning] [30B-A3B]	NVIDIA-Nemotron-3-Super-120B-A12B 05-03-10 @ nvidia-open-model-license [LLM] [1M context] [reasoning] [tools] [120B-A12B]
NVIDIA-Nemotron-3-Nano-4B 05-03-07 @ nvidia-open-model-license [LLM] [256k context] [reasoning] [4B]	Qwen3.5-0.8B 05-03-02 @ apache-2.0 [LLM] [256k context] [reasoning] [tools] [vision] [0.8B]	Qwen3.5-2B 05-03-02 @ apache-2.0 [LLM] [256k context] [reasoning] [tools] [vision] [2B]

The screenshot shows the Dvzhihi website interface. At the top, there's a navigation bar with links like 'Главная', 'О нас', 'Контакты', 'Политика конфиденциальности', and 'Условия использования'. Below the navigation bar, the main heading reads 'подключаемые inference-рантаймы'. The content area displays a grid of inference runtimes, each with a logo, name, and supported frameworks. The runtimes shown include vLLM, SGLang, Llama.cpp, and others. Each runtime entry has a 'Built-in' label and a list of supported frameworks like CUDA, ROCm, and MPS.

Статистика

токены и запросы по пользователям и ключам

16,2B Input Tokens 92,1M Output Tokens 16,3B Total Tokens 343K API Requests 32 Models Used

Метрика: Total Tokens Group by: Day Week Month

1.5B
1.2B
900K
600K
300K
0


09-01 09-02 09-03 09-04 09-05 09-06 09-07 09-08 09-09 09-10 09-11 09-12 09-13 09-14 09-15 09-16 09-17 09-18 09-19 09-20 09-21 09-22 09-23 09-24 09-25 09-26 09-27 09-28 09-29 09-30

■ Total Tokens

Models	Users	API Keys				
Name	Input Tokens	Input Tokens Cached	Output Tokens	Total Tokens	API Requests	Last Active
qwem	1196107563	10347601835	81363471	12042420434	145007	2025-09-30
tgm-m3-nussian-legal	2487102006	0	0	2487102006	67818	2025-09-30

Продолжаем тюнить

Proxmox, GPUStack, llama.cpp



Почти получилось — для 1 отдела хватит

Параметр	Ожидание	Реальность	Статус
● СКОРОСТЬ	80–100 ток/сек	50–70 ток/сек	~
● КОНТЕКСТ	256k токенов	32–64k	✗
● ОБЪЁМ	50M токенов/сутки на чел.	2–3 пользователя, но тормоза	✗
● КАЧЕСТВО	≥ Claude 3.5 Sonnet	Не ясно как подобрать модель	~
● API	OpenAI / Anthropic	OpenAI-совместимый	✓
● УПРАВЛЕНИЕ	Статистика и управление доступами	GPUStack	✓

ОСОБЕННОСТИ

Модели еле влезают

RAM помогает запихать модель

2–3 пользователя — предел

не хватает пропускной способности

GPUStack — унификация

ключи, статистика, модели через UI

llama.cpp умеет запускать модели в RAM, когда не хватает VRAM

Что дальше? RTX 3090 + vLLM

01

Перейти на пары RTX 3090

Это даст 48 GB VRAM

02

Заменить llama.cpp на vLLM

Движок адаптирован под production нагрузку

03

Подобрать версию модели под железо

Изучить виды квантизации, особенности алгоритмов

04

Настроить контроль температура-мощность

Написать демона, который сам будет следить за перегревом

05

Запустить балансировщик LLM трафика

sticky session + prefix-aware (vllm router или свой балансер)

06

Встроить ИИ в рабочий процесс

CI review, SDLC, RAG

Подбор модели под железо

$$\text{VRAM} = \text{BECA (КВАНТИЗАЦИЯ)} + \text{KV-CACHE (КОНТЕКСТ} \times \text{CONCURRENCY)} + \text{OVERHEAD (~10-15\%)}$$

≈ 24 GB

48 GB


FP16

без квантизации

× OOM

AWQ INT4

W4A16



01 Возможный вес модели

Размер файлов модели –
минимальный бъем VRAM

14 GB → 14+ GB VRAM

>

02 Требуемый объем памяти

в зависимости от движка

llama.cpp → 1 x размер модели

vLLM → 2 x размер модели

>

03 Квантизация

по поколению GPU


Ampere (30**) → AWQ (W4A16)

Ada Lovelace (40**) → NVFP4

На Ampere нет FP8 — поэтому 27B на 2×3090 живёт в AWQ INT4

Что настраивать в движке inference?


Группа	vLLM	llama.cpp / Ollama
● A Память / KV-cache	gpu-memory-utilization 0.85-0.92 · max-model-len	n_ctx · n_gpu_layers
● B Batching / scheduler	max-num-seqs · max-num-batched-tokens 4096-16384 · chunked-prefill	n_batch · threads = физ. ядра
● C Ускорения	speculative decoding (MTP/EAGLE) · flash attn · prefix caching	flash attention · MTP draft-tokens
● D Железо / топология	tensor-parallel-size · pipeline-parallel-size · OMP_NUM_THREADS	n_gpu_layers (offload) · --threads



конфиг для qwen3.8-27b


Один параметр за раз — иначе не поймёшь, что именно дало эффект

Особенности LLM трафика



Запрос обрабатывается секунды, кэш протухает — балансировать надо нагрузку и кэш


Балансировка LLM трафика



Балансер роутит по кэшу и нагрузке: сессия — на тёплую, новую — на холодную

Что в итоге?

AWQ, vLLM, балансер



Итоги

Параметр	Ожидание	Реальность	Статус
● СКОРОСТЬ	80–100 ток/сек	80-100 ток/сек на пользователя	✓
● КОНТЕКСТ	256k токенов	256K (262144)	✓
● ОБЪЁМ	50M токенов/сутки на чел.	1 млрд токенов/сутки (пик), 600-750M в среднем	✓
● КАЧЕСТВО	≥ Claude 3.5 Sonnet	Qwen3.8: Terminal-Bench 73, DeepSWE 42.2	✓
● API	OpenAI / Anthropic	GPUStack — OpenAI-совместимый	✓
● УПРАВЛЕНИЕ	Статистика и управление доступами	GPUStack: счётчики по пользователям и API-ключам	✓

ОСОБЕННОСТИ

10 сотрудников работают

Каждый может в 3 потока кодить

<74°C температура видеокарт

При допустимой в 93°C

ИИ встроен везде

Агенты, Chat, RAG, DeerFlow, Dify...

Спасибо! Вопросы?

1 млрд токенов в сутки — это про комбинацию железа + модели + конфигов + эксперименты.

Александр Сапронов

`a@sapronov.me` · `t.me/axsapronov`



как повторить



слайды